

치아 3D 스캔 데이터 세그멘테이션 모델 개발: 불규칙 데이터 학습 및 DilatedToothSegNet 기법 활용 (Development of a Dental 3D Scan Data Segmentation Model: Learning from Irregular Data & DilatedToothSegNet Method)

조상원* 이현상*, 이병우**, 유건재***지진우, 김희길, 김종덕
(Hyun Sang Lee,)

요약

본 연구는 치과 진료 현장에서 빈번하게 발생하는 작업치 및 국소 스캔 데이터를 포함한 치아 3D 스캔 데이터를 자체적으로 수집하고 레이블링하여, 치아 번호별 3D 세그멘테이션 모델의 실무 적용 가능성을 높이고자 한다. 기존 연구들은 전체 구강 구조의 3D 이미지 데이터를 활용하는 데 한정되어 실제 임상 데이터의 불규칙성을 충분히 반영하지 못했다. 이를 개선하기 위해, 본 연구에서는 작업치(크라운, 임플란트, 인레이)와 국소 스캔 데이터를 포함한 총 910건의 3D 치아 스캔 데이터를 수집하고, 15개의 클래스(치은 및 치아 번호별)로 라벨링하였다. 딥러닝 모델로는 MeshSegNet과 DilatedToothSegNet을 사용했으며, 각각 메쉬 셀을 10,000개와 16,000개로 다운샘플링하여 학습했다. 결과적으로 DilatedToothSegNet(16,000 cells)이 모든 성능 지표에서 가장 우수했다. 또한, 딥러닝 모델들의 3D 세그멘테이션 예측 결과를 분석했을 때, 작업치 포함 국소 스캔 데이터에서도 DilatedToothSegNet 모델이 안정적인 예측 결과를 도출했음을 확인했다. 본 연구를 통해, 딥러닝 기반 치아 3D 세그멘테이션 기술이 실제 임상 환경에서의 적용 가능성을 높이고, 치과 진료의 효율성과 정확성을 향상시키는 데 기여할 것으로 기대한다.

■ 중심어 : 3D 세그멘테이션, 치아 3D 스캔 데이터, 딥러닝, 불규칙 데이터 학습, DilatedToothSegNet

Abstract

This research aims to enhance the practical applicability of tooth number-based 3D segmentation models by independently collecting and labeling dental 3D scan data, including frequently occurring restorative teeth and local scan data in dental practices. Previous researches were limited to utilizing 3D image data of the entire dentoalveolar structure, failing to adequately reflect the irregularities of actual clinical data. To overcome this issue, we collected a total of 910 3D teeth scan data, including restorative teeth (crowns, implants, inlays) and local scan data, and labeled them into 15 classes (gingiva and tooth numbers). Deep learning models such as MeshSegNet and DilatedToothSegNet were used, with each model trained using downsampled mesh cells of 10,000 and 16,000. As a result, DilatedToothSegNet (16,000 cells) demonstrated superior performance across all metrics. Furthermore, when analyzing the 3D samples segmentation predictions of the deep learning models, [The DilatedToothSegNet model produced stable predictions even with local scan data that included restorative teeth.](#) We expect this research to contribute to improving the efficiency and accuracy of dental care by increasing the applicability of deep learning-based tooth 3D segmentation technology in real clinical environments.

■ keywords : 3D segmentation, teeth 3D scan data, deep learning, irregular data learning, DilatedToothSegNet

I. 서론

디지털 덴티스트리는 진단, 치료 계획, 보철물 제작 등 분야에서 IT 기술의 발전에 따라 치과의료를 혁신하고 있다[1]. CAD/CAM, 3D 프린팅,

인공지능, 증강 현실, 텔레덴티스트리 등 다양한 기술이 포함되며, 이 기술들은 치과 치료의 정확성과 효율성을 크게 개선했다. 특히 국내에서는 2022년 전국민의 47.1%가 치과 진료를 이용하고

* 학생회원, 00대학교 000학과 (종고덕, 8.5pt, 장평93%, 자간-7%, 왼쪽10pt, 오른쪽 10pt, 줄간격120%)

** 정회원, 00대학교 000학과

[이 논문은 2011년도 정부(교육과학기술부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (No. 2000-00000000).]

접수일자 : 2020년 03월 23일 (학회측 사용란)

게재확정일 : 2020년 03월 28일 (학회측 사용란)

수정일자 : 1차 2020년 03월 23일, 2차 2020년 04월 23일(학회측 사용란)

교신저자 : 홍길동, 김정민 e-mail : jmkim@jnu.ac.kr

이현상 2024/10/02 02:17

제목 펜참은지 검토

yu 2024/10/08 11:36

이현상 2024/10/01 12:51

참여 저자 입력(수정 진행중)

이현상 2024/10/02 02:33

인적사항 정리

yu 2024/10/08 11:37

진행중

이현상 2024/10/02 02:33

사사 추가 확인

yu 2024/10/08 11:36

사사 삭제 예정

있다고 조사가 되었으며, 치과 진료 환자의 약 40%가 보철 치료 건에 해당한다고 발표되었다 [2, 3]. 현재 치과에서의 보철 치료는 구강 스캔부터 환자 맞춤형 보철물 제작, 적합 검사 등의 과정이 필요하며, 특히 치아 보철물 제작을 위한 인상에 대해서 전달하고 제작하는 과정에서 가장 많은 시간과 비용이 소요되고 있다[4].

이에 디지털덴티스트리 분야에서는 딥러닝 기술을 통해서 3D 구강 스캔 이미지의 치아 영역을 식별하는 방식으로 보철물 제작을 지원하는 기술을 연구하고 있다[5, 6, 7]. 해당 분야에서는 3D 세그멘테이션(segmentation) 기술을 활용하여 치아 번호별 3D 영역을 탐지할 수 있는 AI 모델을 개발했다. 이러한 자동화 기술을 통해, 보철물 제작 과정에서 인상 채득 및 전달 과정을 간소화하고, 제작 시간을 단축하며, 보철물 설계의 정확성과 적합도를 개선할 수 있다.

그러나 기존 연구에서는 전체 구강 구조의 3D 이미지 데이터를 활용했다는 한계점을 가지고 있다[5, 6, 7]. 실제 치과 환자들을 대상으로 스캔한 3D 이미지에는 2가지 특징이 있는데, 첫 번째로는 치과 환자가 이미 임플란트, 크라운, 인레이 등의 작업치를 가지고 있는 경우가 존재한다는 것이다. 두 번째, 보철물 제작의 상황에 따라서 환자 치아의 국소 영역만을 스캔하는 경우가 있다. 이는 본 연구에서 수집된 실제 치과 환자들의 구강 스캔 데이터를 탐색했을 때 발견된 사례들이며, 기존 연구에서 학습된 AI 모델은 해당 데이터에 대해 세그멘테이션 추론을 수행할 수 없다는 문제점을 가지고 있다.

이에 따라 본 연구에서는 치과 진료 실무에서의 활용을 위해 작업치 및 국소 스캔 데이터가 포함된 치아 3D 데이터를 자체 수집했다. AI 학습용 데이터셋 구축을 위한 전처리의 경우 작업치 및 국소 스캔 데이터도 전체 구강 스캔 데이터와 동일한 기준으로 치아 번호별 세그멘테이션 라벨링을 수행했다. 실험 단계에서는 치아 3D 세그멘테이션 분야에서 활용되는 MeshSegNet

과 DilatedToothSegNet 딥러닝 모델들을 학습하여 예측 성능을 비교 분석했다[5, 7].

II. 선행 연구

1. 3D 이미지 세그멘테이션

3D 이미지 세그멘테이션은 의료 영상 처리 분야에서 중요한 연구 주제 중 하나로, 3D 의료 이미지 데이터에서 관심 영역을 분리하고 분석하는 데 사용된다. 실제로 활용되는 연구 중 하나로, 간 분할(liver segmentation)을 위해 3D 복부 CT 영상을 활용한 방법이 있다. Otsu 임계값 기법을 사용해 간 영역을 자동으로 세그멘테이션하여 최소한의 수작업 개입으로 기존 반자동 방법보다 더 효율적이고 일관된 결과를 제공한다 [8]. 기존의 2D 세그멘테이션 기법은 단면적인 정보만을 활용하므로 3D 구조의 복잡한 공간적 관계를 완벽하게 반영하지 못한다[9]. 이에 반해 3D 세그멘테이션은 볼륨 데이터를 전체적으로 분석하여 정확하고 정밀한 결과를 제공한다. 초기에는 수동 또는 반자동화된 방법을 통해 3D 세그멘테이션이 활용되었으나, 이는 전문가의 개입이 필요하고 시간과 비용이 많이 소요되는 단점이 있었다. 최근에는 딥러닝의 발전으로 인해 AI를 기반으로 자동화된 3D 세그멘테이션을 연구하고 있으며, 특히 3D 컨볼루션 신경망을 활용한 방법들이 개발되었다[10, 11].

3D U-Net과 같은 모델은 3D 의료 이미지 세그멘테이션에서 널리 사용되고 있으며, 인코더 및 디코더 구조를 통해 다양한 크기의 특징을 효과적으로 학습한다. 이 모델은 적은 양의 데이터로도 높은 성능을 발휘할 수 있어 의료 분야에서 유용하다[9]. 특히, 다중 필터를 결합한 MFUNet은 U-Net 구조를 확장하여 간 영역 분할 성능을 개선했으며, CT 이미지에서 더욱 정확한 분할할 수 있는 가능성을 제시했다[12]. 최근에는 기존의 U-Net 구조에 어텐션 메커니즘(Attention

yu

2024/10/08 11:45

참고문헌 스마트미디어저널 논문 3편

추가 8, 12, 13

Mechanism)을 추가하여, 의료 이미지를 더 효과적으로 분할하는 방법을 제안했다[13]. 또한, V-Net은 잔차 구조를 도입하여 학습의 효율성을 높였으며, 다중 스케일의 특징을 활용하여 정확한 세그멘테이션을 가능하게 한다[11]. 포인트 클라우드 데이터를 직접 처리하는 딥러닝 모델인 PointNet도 3D 세그멘테이션에 활용되고 있다[11]. 해당 모델은 3D 공간에서의 점 데이터의 구조적 특징을 학습하여 복잡한 형태의 객체를 정확하게 세그멘테이션할 수 있다.

2. 치아 번호별 3D 세그멘테이션

치아 번호별 3D 세그멘테이션 연구에서는 환자 각각의 치열 불규칙성으로 인한 라벨링 자동화의 어려움을 지적하면서, 딥러닝 기반의 접근법을 제시했다. MeshSegNet은 다양한 크기의 로컬 컨텍스트 정보를 학습하여, 서로 다른 치아의 형상과 위치 변화를 효과적으로 포착할 수 있도록 설계되었다[5]. 이 모델은 인접한 메쉬 셀들 사이의 공간적 관계를 그래프 구조로 모델링하여, 치아 간 경계를 명확하게 분리하고 라벨링 정확도를 개선했다. 또한, 치아의 로컬 특징과 전체 치아 표면의 글로벌 특징을 결합하여, 각 메쉬 셀을 보다 정밀하게 분류할 수 있다. 후처리 단계에서는 그래프 컷(Graph Cut) 알고리즘을 통해 부정확한 예측 결과를 개선하고 세그멘테이션 영역의 자연스러운 경계를 유지할 수 있다.

DilatedToothSegNet은 기존의 구강 스캔 데이터에서 치아가 없거나 비정상적인 배열을 가지고 있는 경우의 세그멘테이션이 어렵다는 한계점을 보완하기 위해, 확장 엣지 컨볼루션(dilated edge convolution)과 동적 엣지 컨볼루션(dynamic edge convolution) 기법을 활용했다[7]. 확장 엣지 컨볼루션은 3D 데이터의 국소적인 특징을 학습하여 정밀한 세그멘테이션을 가능하게 하며, 동적 엣지 컨볼루션은 필터의 수용범위를 확장하여, 인접 치아 및 주변 영역의 특징을 활용할 수 있게 한다. DilatedToothSegNet

모델은 Teeth3DS라는 벤치마크 데이터셋을 사용하여 다양한 최신 기술들과 비교했으며, 그 결과 우수한 성능을 나타냈다.

III. 연구 방법론

1. 데이터

치아 3D Segmentation 학습용 데이터는 실제 치과 환자들의 치아를 스캔한 샘플들을 (주)글라우드에서 제공받았으며, 총 930건의 데이터를 수집했다. 해당 수집 데이터는 그림 1과 같이 상악과 하악으로 구분되며, stl 확장자로 저장되었다. 또한, 1개의 3D 이미지는 100,000개 이상의 메쉬 셀(mesh cell)로 구성되어 있다. 본 연구에서는 구강 전체 스캔 이미지뿐만 아니라 그림 2, 3과 같이 국소 스캔, 작업치 등의 불규칙한 특징을 가지고 있는 데이터도 같이 수집되었다. 작업치 데이터의 경우 크라운, 임플란트, 인레이로 정의되며, 두 개 이상의 개수 및 카테고리가 포함된 데이터도 존재한다. 마지막으로 그림 4와 같이 스캔된 치아가 정상적인 배열이 아니거나 단면만 존재하는 경우에도, 본 연구의 치과 진료 실무 적용을 위한 목적성에 따라 학습용 데이터셋으로 구축했다.



그림 1. 3D 스캔 데이터 샘플 1
(좌 - 상악, 우 - 하악)




그림 2. 3D 스캔 데이터 샘플 2
(좌 - 전체 스캔, 우 - 국소 스캔)




그림 3. 3D 스캔 데이터 샘플 3
(좌 - 크라운, 중간-임플란트, 우 - 인레이)




그림 4. 3D 스캔 데이터 샘플 4
(좌 - 비정상 배열, 우 - 치아 단면 스캔)

일반적으로 성인의 치아 개수는 제3대구치(사랑니)를 제외하고 상악과 하악 각각 14개로 구성된다. 본 연구에서 제공된 샘플에서 좌우측의 대구치(어금니) 두 개를 제외한 15번째 치아가 존재하는 경우, 이를 제3대구치로 처리했다. 제3대구치 샘플은 일반적으로 성인의 경우 제거 수술

을 받는 경우가 많기 때문에, 노이즈 데이터로 판단하여 제거했다.

[치아 번호 클래스의 경우 치은(잇몸)을 포함하여 총 15개로 라벨을 부여했다. 상악과 하악 모두 좌측 첫 번째 대구치부터 우측 끝 대구치까지 1번부터 14번으로 지정했으며, 0번 클래스는 치은에 해당한다. 특히 5번과 10번 클래스는 견치(송곳니)를, 7번과 8번 클래스는 절치(앞니)를 나타낸다. 전체 930건의 데이터 중 제3대구치가 포함된 12개와 학습에 사용 불가능하다고 판단되는 데이터 8개를 제외한 후, 상악과 하악으로 분류한 결과 각각 475건과 435건의 데이터를 확보했다. 세부적인 데이터 구성은 표 1과 같이, 정상치와 작업치(크라운, 임플란트, 인레이), 그리고 작업치가 2개 이상 포함된 데이터로 구분되었다.

표 1. 작업치 데이터셋 구성

데이터 구분	상악	하악	합계
정상치	96	148	244
크라운	142	123	265
임플란트	162	88	250
인레이	50	52	102
두 종류 이상	25	24	49
합계	475	435	910

데이터 라벨링 작업은 지정된 클래스에 따라 Mesh Labeler 도구를 활용하여 수행되었다[15, 16]. 라벨링이 완료된 샘플들은 후속 처리와 모델 학습에 적합하도록 vtp 확장자 파일로 변환하여 라벨링 데이터셋을 구축했다. 치아와 치은을 포함하여 총 0번부터 14번까지 15개의 라벨이 부여되었으며, [그림 5는 모든 클래스가 존재하는 샘플의 라벨링 결과를 나타낸다.

yu 2024/10/08 11:39
상악과 하악 모두 포함한다는 내용으로 수정

이현상 2024/10/02 17:02
초안에서의 추후 수정 사항 고려하여 레이아웃 일단 놔둬

yu 2024/10/08 11:41
구체적인 클래스 번호에 대한 그림 수정




그림 5. 15개 클래스 라벨링 데이터 예시

최종 검토 작업이 완료된 전체 치아 데이터는 표 2와 같이 상악 475건과 하악 435건으로 구성되었다. 모델의 학습과 평가를 위해 전체 데이터셋을 8:1:1 비율로 분할했다. 구체적으로, 학습 데이터셋은 상악 379건과 하악 347건, 검증 데이터셋은 상악 48건과 하악 44건, 테스트 데이터셋은 상악 48건과 하악 44건으로 구성했다.

표 2. 학습, 검증, 테스트 데이터셋 구성

데이터 구분	상악	하악	합계
학습(Train)	379	347	726
검증(Val)	48	44	92
테스트(Test)	48	44	92
합계	475	435	910

2. 딥러닝 모델 개발

본 연구에서는 딥러닝 기반 치아 3D 세그멘테이션 모델 개발을 위해 Github의 소스코드를 참고하여 MeshSegNet과 DilatedToothSegNet 모델을 각각 학습시키고 그 성능을 비교 분석했다 [17, 18]. 원본 이미지 데이터는 100,000개 이상의 메쉬 셀로 구성되어 있어 고해상도 메쉬 표면의 세분화 작업을 보다 효율적으로 처리하기 위해, 일반적으로 사용되는 다운샘플링

(downsampling) 방식을 적용하여 전처리했다 [7]. MeshSegNet의 경우 기존 연구를 참고하여 10,000개의 메쉬 셀로 다운샘플링을 진행했으며 [5], DilatedToothSegNet 모델 또한, 기존 연구에서 사용된 16,000개의 셀로 다운샘플링하였다.

이후, 두 모델의 기준이 다르기 때문에 보다 구체적인 성능을 비교하기 위해 MeshSegNet에서도 DilatedToothSegNet을 참고하여 16,000개의 메쉬 셀로 추가적인 모델을 구축했다. 이는 더욱 세밀한 세그멘테이션 성능을 얻기 위한 실험으로, 기존 10,000개 셀의 모델과 비교하여 고해상도 데이터를 처리하는 성능 차이를 확인하고자 했다. 두 모델 모두 일반화 능력을 높이기 위해 동일한 데이터 증강 기법을 적용했다. 데이터 증강 과정에서는 무작위 회전(random rotation), 무작위 평행 이동(random translation), 무작위 스케일링(random scaling)을 활용하여 각 샘플당 20회의 증강을 수행했다. 본 연구의 증강 기법은 3D 세그멘테이션 모델이 다양한 데이터의 변형에 대해 견고한 성능을 보일 수 있도록 설계되었다.

총 3가지의 딥러닝 모델은 15개의 치은 및 치아번호별 클래스를 세그멘테이션할 수 있도록 학습되었다. 3D 데이터 특성상 데이터가 무겁고 학습 속도가 느리기 때문에 GPU 자원을 효율적으로 활용하기 위해 세 모델 모두 학습 에포크(epochs)를 100으로 설정하여 학습을 진행했다. 이를 통해 충분한 학습을 보장하면서도 학습 시간이 과도하게 늘어나는 것을 방지하고자 했다.

3. 성능 지표

본 연구에서는 3D 치아 세그멘테이션 모델의 예측 성능 평가를 위해 두 가지 주요 성능 지표를 적용했다. 첫 번째로 사용된 지표는 Macro Dice Similarity Coefficient(Macro DSC)이다. DSC는 (1)의 식과 같이, 예측된 세그멘테이션 영역과 실제 클래스 간의 교집합을 두 영역의 합

yu 2024/10/08 11:38
loss 내용 제거 후 전처리 부분 내용 추가

으로 나눈 값으로 계산되며, 3D 세그멘테이션에서는 예측된 3D 메쉬와 실제 메쉬 간의 겹치는 영역을 측정하는 데 사용된다[16]. Macro DSC는 식 (2)처럼 각 클래스별 DSC를 계산한 후 평균을 구하여 전체적인 성능을 평가한다. 이를 통해 특정 클래스에 편중되지 않은 성능 평가가 가능하다. 여기서 P는 예측된 세그멘테이션 영역을, G는 실제 영역을 나타내며, $P \cap G$ 는 이 두 영역의 교집합을 의미한다. DSC 값은 0에서 1 사이의 값을 가지며, 값이 1에 가까울수록 예측이 실제와 유사함을 나타낸다.

$$DSC = \frac{2|P \cap G|}{|P| + |G|} \tag{1}$$

$$Macro\ DSC = \frac{1}{C} \sum_{c=1}^C DSC_c \tag{2}$$

두 번째 지표는 Mean Intersection over Union(mIoU)이다. IoU는 식 (3)과 같이, 예측된 세그멘테이션 영역과 실제 클래스 간의 교집합을 합집합으로 나눈 값으로 계산된다[20]. DSC는 교차 영역의 중요성이 강조되며, IoU 지표의 경우 작은 크기의 영역 예측에 민감하다는 점에서 차이점이 존재한다. mIoU는 식 (4)와 같이, 각 클래스별 IoU를 계산한 후 모든 클래스의 평균을 구하여 전체적인 예측 성능을 산출한다. 여기서 PUG는 예측된 영역과 실제 영역의 합집합을 의미한다. mIoU 값 또한 0에서 1 사이의 값을 가지며, 값이 1에 가까울수록 예측된 영역이 실제 영역과의 일치도가 높음을 의미한다.

$$IoU = \frac{|P \cap G|}{|P \cup G|} \tag{3}$$

$$mIoU = \frac{1}{C} \sum_{c=1}^C IoU_c \tag{4}$$

4. 후처리

본 연구에서는 3차원 치아 세그멘테이션의 예측 결과를 보정하여 성능을 향상시키기 위한 후처리 과정을 수행했다. 3D 스캔 데이터는 그 특성상 높은 복잡성과 다양한 불규칙성을 지니고

있어, 기존의 예측 결과만으로는 정확한 수준의 예측 성능을 달성하기 어렵다. 따라서 최종 예측 단계에서 효과적인 후처리 기법을 적용하여 모델의 성능을 개선하고자 했다.

후처리 단계에서는 구체적으로 SVM(Support Vector Machine)을 활용하여 업샘플링(upsampling) 기법을 적용함으로써, 원본 메쉬 셀로 라벨을 확장하여 보다 세밀한 세그멘테이션 예측을 수행했다[21]. 추가적으로, Pygco 라이브러리를 활용한 그래프 컷 기반의 정제 과정을 수행했다[22]. 이 과정에서는 각 메쉬 셀 간의 거리와 노멀 벡터의 유사성을 고려하여 에너지 함수를 정의하고, 그래프 컷 알고리즘을 통해 라벨의 일관성을 유지했다.

IV. 실험 결과

1. 성능 지표 비교

본 연구에서는 10,000개 및 16,000개 메쉬 셀 입력 MeshSegNet 모델, 16,000개 메쉬 셀 DilatedToothSegNet 총 3가지 모델의 치아 3D 세그멘테이션 예측 성능을 MDSC(Macro Dice Similarity Coefficient)와 mIoU을 기준으로 평가했다. 그 결과는 표3과 같이 나타나며, 16,000개 셀의 DilatedToothSegNet이 모든 지표 부문에서 가장 우수한 성능을 달성했다.

표 3. 상·하악별 치아 세그멘테이션 지표 측정 결과

모델명	상악 Test	하악 Test	상악 Test	하악 Test
	MDSC	MDSC	mIoU	mIoU
MeshSegNet (10,000 Cells)	0.878	0.859	0.771	0.751
MeshSegNet (16,000 Cells)	0.897	0.879	0.798	0.775
DillatedTooth SegNet (16,000 Cells)	0.919	0.908	0.852	0.833

MDSC 지표에서는 상악보다 하악에서의 성능 향상이 크게 나타나는 것으로 고려했을 때, DilatedToothSegNet이 하악의 복잡한 해부학적 구조를 효과적으로 포착하고 변칙적인 치아 세그멘테이션에 강점을 보였다고 해석된다. 반면 mIoU의 경우 상악과 하악에서 일정한 수준의 성능 향상이 있었던 것으로 보았을 때, 영역의 크기가 작은 객체에 대한 세그멘테이션에서도 DilatedToothSegNet이 안정적인 성능으로 작은 치아나 미세한 구조에도 정확한 분할이 가능하다고 해석할 수 있다.

2. 세그멘테이션 테스트 결과 비교

실제 테스트 데이터셋의 세그멘테이션 결과는 **그림 9와 그림 10**에 제시되어 있다. 그림 9는 상악 테스트 데이터셋의 치아 스캔 이미지 샘플에 대한 딥러닝 모델들의 3D 세그멘테이션 예측 결과를, 그림 10은 하악에 대한 결과를 나타낸다.

그림 9에서 상악 샘플의 국소 영역 스캔 데이터를 대상으로 세그멘테이션을 수행한 결과, MeshSegNet은 치아의 경계선을 정확하게 포착하지 못하고 인접한 치아를 구분하는 데 어려움을 보였다. 이는 국소 영역 스캔 데이터에서의 복잡한 치아 구조와 제한된 정보로 인해 모델의 일반화 능력이 저하된 것으로 해석된다. 반면, DilatedToothSegNet은 이러한 국소 영역에서도 치아의 경계선을 비교적 정확하게 예측했으며, 이는 모델의 확장된 수용 영역과 다중 스케일 특징 추출 기능 덕분으로 판단된다[7].

작업치가 포함된 샘플의 경우, MeshSegNet은 데이터의 불규칙한 패턴과 치아 배열의 변화로 인해 치아 번호 라벨을 잘못 예측하거나 특정 치아를 누락하는 현상이 발생했다. 그러나 DilatedToothSegNet은 작업치가 포함된 3D 스캔 이미지에서도 정확한 치아 번호별 세그멘테이션을 수행했으며, 이는 모델이 다양한 형태의 치아 배열과 결손에 대해 강건(robust)한 성능을

보임을 시사한다. 또한, 불규칙한 치열을 가진 샘플에서도 MeshSegNet은 치아 번호별로 정확한 세그멘테이션을 수행하지 못했으나, DilatedToothSegNet은 불규칙한 치열의 국소 스캔 데이터에서도 높은 예측 정확도를 유지했다.


그림 10의 하악 샘플에서는 국소 스캔 및 작업치가 포함된 샘플을 대상으로 한 세그멘테이션 결과를 분석했다. MeshSegNet은 하악의 복잡한 해부학적 구조와 국소 영역의 제한된 정보로 인해 치아 영역의 경계를 정확하게 포착하지 못하고, 치아 간의 구분이 불명확했다. 반면, DilatedToothSegNet은 하악의 복잡한 구조에서도 치아의 경계를 명확하게 구분하고, 세부적인 구조를 효과적으로 반영한 세그멘테이션 결과를 보여주었다.

yu

2024/10/08 11:43

차이점이 보이는 이미지로 교체

<MeshSegNet(10,000 cells)>




<MeshSegNet(16,000 cells)>





<DilatedToothSegNet(16,000 cells)>





<구강 국소 영역 스캔 3D 이미지 세그멘테이션>





<작업치(임플란트) 포함 3D 이미지 세그멘테이션>



<작업치(크라운) 포함 3D 이미지 세그멘테이션>




<작업치(인레이) 포함 3D 이미지 세그멘테이션>




<불규칙 치열 스캔 3D 이미지 세그멘테이션>

그림 9. 상악 치아 테스트셋 3D 이미지 샘플 세그멘테이션 결과


<MeshSegNet(10,000 cells)>






<MeshSegNet(16,000 cells)>





<DilatedToothSegNet(16,000 cells)>




<구강 국소 영역 스캔 3D 이미지 세그멘테이션>




<작업치(임플란트) 포함 3D 이미지 세그멘테이션>



<작업치(크라운) 포함 3D 이미지 세그멘테이션>



<작업치(인레이) 포함 3D 이미지 세그멘테이션>



<불규칙 치열 스캔 3D 이미지 세그멘테이션>

그림 10. 하악 치아 테스트셋 3D 이미지 샘플 세그멘테이션 결과

V. 결론

본 연구에서는 치과 진료 현장에서 실제로 접할 수 있는 작업치 및 국소 스캔 데이터를 포함한 치아 3D 스캔 데이터를 자체적으로 수집하고 레이블링하여, 치아 번호별 3D 세그멘테이션 모델의 실무 적용 가능성을 개선하고자 했다. MeshSegNet과 DilatedToothSegNet 등 최신 딥러닝 기법을 활용하여 모델을 학습하고, MDSC와 mIoU 지표를 통해 성능을 비교 분석한 결과, DilatedToothSegNet 모델이 모든 지표에서 우수한 성능을 달성했다. 특히 국소 영역 및 작업치 포함 3D 이미지에 대한 세그멘테이션 결과에서 우수한 성능을 나타내어, 실제 임상 환경에서의 활용 가능성을 입증했다.

이러한 결과는 다음과 같은 시사점을 제공한다. 첫째, 치과 진료 현장 실무에서는 구강 스캔 데이터의 불규칙성을 고려한 데이터 구성이 필요하다. 본 연구에서는 작업치, 국소 스캔 등 실무에서 빈번히 발생하는 불규칙한 데이터를 포함하여 모델을 학습시킴으로써, 실제 환경에서의 일반화 능력을 향상시켰다. 둘째, MeshSegNet과 DilatedToothSegNet 등 최신 딥러닝 기법의 실험을 통해, 복잡한 치아 구조와 형태 변이에 효과적으로 대응할 수 있는 모델의 성능을 실증했다. 특히 DilatedToothSegNet의 뛰어난 성능은 딥러닝 기술이 치아 3D 세그멘테이션 분야에서의 잠재력을 보여준다. 셋째, 본 연구에서는 데이터셋 수집부터 레이블링까지 자체 수행하여, 실제 환자 임상 데이터를 반영한 고품질의 데이터셋을 구축했다는 점에서 의의가 있다.

그러나 본 연구는 데이터셋의 규모와 다양성에 있어 일부 한계점을 가진다. 수집된 데이터가 특정 지역이나 기관에 한정되어 있어, 다양한 인구 집단의 치아 구조를 완벽히 반영하지 못할 수 있다. 향후 연구에서는 더 다양한 환자군과 치아 이상 사례를 포함한 대규모 데이터셋을 구축하여 모델의 범용성을 강화할 필요가 있다. 또한,

개발된 모델을 실제 임상 환경에 적용하여 그 유용성과 실효성을 검증하는 과정이 필요하다. 본 연구를 통해, 딥러닝 기반 치아 3D 세그멘테이션 기술이 치과 진료의 효율성과 정확성을 향상시키는 데 실질적으로 기여할 수 있을 것으로 기대한다.

REFERENCES

- [1] Z. S. Haidar, "Digital Dentistry: Past, Present, and Future," Digital Medicine and Healthcare Technology, vol. 2, 2023.
- [2] 치과의료정책연구원, "우리나라 국민의 외래 치과 의료비 지출 경향," 제22호, 2020.
- [3] 의과학연구정보센터, 우리나라 보철치료 현황 및 경제성 평가, 2023.
- [4] 김려운, 장근원, 허유리, 손미경, "치과 디지털 인상 의 이해와 적용," 대한치과재료학회지, 제41권, 제4호, pp. 253-261, 2014.
- [5] C. Lian, L. Wang, T. H. Wu, F. Wang, P. T. Yap, C. C. Ko, and D. Shen, "Deep Multi-Scale Mesh Feature Learning for Automated Labeling of Raw Dental Surfaces from 3D Intraoral Scanners," IEEE Transactions on Medical Imaging, vol. 39, no. 7, pp. 2440-2450, 2020.
- [6] J.-S. An and Y.-R. Cho, "Performance Comparison of 3D Segmentation Models Based on Point Cloud and Mesh for Dental Scan Data," KIISE Transactions on Computing Practices, vol. 29, no. 4, pp. 158-165, 2023.
- [7] L. Krenmayr, R. von Schwerin, D. Schaudt, P. Riedel, and A. Hafner, "DilatedToothSegNet: Tooth Segmentation Network on 3D Dental Meshes Through Increasing Receptive Vision," Journal of Imaging and Information Medicine, vol. 37, no. 4, pp. 1846-1862, 2024.
- [8] Hong Tai Tran, A Ran Oh, In Seop Na, Soo Hyung Kim, "Liver Segmentation and 3D Modeling from Abdominal CT Images," 스마트미디어저널, 5권, 1호, 1-6, 2016.
- [9] M. A. Balafar, A. R. Ramli, M. I. Saripan, and S. Mashohor, "Review of Brain MRI Image Segmentation Methods," Artificial Intelligence Review, vol. 33, no. 3, pp. 261-274, 2010.
- [10] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, and O. Ronneberger, "3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation," in Proceedings of the 19th International Conference on Medical Image

이현상

2024/10/08 20:49

사업계획서보고 ref 넣은건데, 원본 출처 찾아서 보완 필요

Computing and Computer-Assisted Intervention (MICCAI 2016), Athens, Greece, 2016.

[11] F. Milletari, N. Navab, and S.-A. Ahmadi, "V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation," in Proceedings of the 2016 Fourth International Conference on 3D Vision (3DV), Stanford, USA, 2016.

[12] Vo Thi Tuong Vi, 오아란, 이귀상, 양형정, 김수형, "Automatic Extraction of Liver Region from Medical Images by Using an MFUnet," 스마트미디어저널, 9권, 3호, 59-70, 2020

[13] Afran Ghafoor, 이범식, "피부 병변 분할을 위한 어텐션 기반 딥러닝 프레임워크," 스마트미디어저널, 권, 호, 53-61, 2024

[14] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, USA, 2017.

[15] T.-H. Wu et al., "Machine (Deep) Learning for Orthodontic CAD/CAM Technologies," in Machine Learning in Dentistry, C. C. Ko, D. Shen, and L. Wang, Eds., Springer, 2021.

[16] Mesh_Labeler Github (2021), https://github.com/Tai-Hsien/Mesh_Labeler (accessed Oct. 2, 2024).

[17] MeshSegNet Github (2020), <https://github.com/Tai-Hsien/MeshSegNet> (accessed Oct. 2, 2024).

[18] DilatedToothSegNet Github (2024), https://github.com/LucasKre/dilated_tooth_seg_net (accessed Oct. 2, 2024).

[19] L. R. Dice, "Measures of the Amount of Ecologic Association Between Species," Ecology, vol. 26, no. 3, pp. 297-302, 1945.

[20] M. Everingham, L. V. Gool, C. K. I. Williams, J. Winn, and A. Zisserman, "The Pascal Visual Object Classes (VOC) Challenge," International Journal of Computer Vision, vol. 88, no. 2, pp. 303-338, 2010.

[21] C. Cortes and V. Vapnik, "Support-Vector Networks," Machine Learning, vol. 20, no. 3, pp. 273-297, 1995.

[22] F. Yi and I. Moon, "Image Segmentation: A Survey of Graph-Cut Methods," in Proceedings of the 2012 International Conference on Systems and Informatics (ICSAI2012), Yantai, China, May 2012.

저자 소개



유건재

2023년 계명대학교 경영정보학과 학사 졸업
2023년 계명대학교 경영정보학과 석사과정

<주관심분야 : 빅데이터, 인공지능, 딥러닝>



이현상

2018년 경북대학교 경영학부 MIS 전공 학사 졸업
2020년 경북대학교 경영학부 MIS 전공 석사 졸업
2022년 경북대학교 경영학부 MIS 전공 박사 수료

<주관심분야 : 머신러닝, 딥러닝>

이현상 2024/10/02 17:00
작성 필요

이현상 2024/10/08 20:50
영어 풀텍스트로 바꾸는게 나을 듯, 권호 출처 찾아보고 없으면 그냥 제거

